

Bioinformatische Anwendung von *Graphlets* zur  
Analyse von Proteinstrukturtopologien zur  
Analyse von Proteinen

Ben Haladik

8. Dezember 2015

# Inhaltsverzeichnis

|          |  |          |
|----------|--|----------|
| <b>1</b> | <b>Einleitung</b>  | <b>2</b> |
| 1.1      | Motivation . . . . .                                     | 2        |
| <b>2</b> | <b>Materialien und Methoden</b>                          | <b>3</b> |
| 2.1      | PLCC . . . . .   | 3        |
| 2.2      | Die PTGL . . . . .                                       | 3        |
| 2.3      | Der <i>Graphlet</i> -Algorithmus . . . . .               | 3        |
| 2.4      | <b>graphletAnalyser</b> . . . . .                        | 5        |
| 2.5      | Scoring . . . . .  | 6        |
| 2.5.1    | Tanimoto-Koeffizient . . . . .                           | 6        |
| 2.5.2    | Relative <i>Graphlet</i> -Häufigkeiten-Distanz . . . . . | 6        |
| 2.5.3    | <i>Root-Mean-Square-Deviation</i> . . . . .              | 6        |
| 2.6      | Datensätze . . . . .                                     | 7        |
| 2.6.1    | FATCAT-SCOP- <i>Benchmarking-Set</i> . . . . .           | 7        |
| 2.6.2    | Fallstudien . . . . .                                    | 7        |
| 2.7      | Ergebnisse . . . . .                                     | 7        |
| 2.8      | Diskussion und Ausblick . . . . .                        | 7        |
| <b>3</b> | <b>Anhang</b>  | <b>8</b> |
| 3.1      | Tabellenverzeichnis . . . . .                            | 8        |
| 3.2      | Bildverzeichnis . . . . .                                | 8        |
| 3.3      | Literaturverzeichnis . . . . .                           | 8        |

# Kapitel 1

## Einleitung

### 1.1 Motivation

## Kapitel 2

# Materialien und Methoden

Um die Proteinstrukturtopologien aus der PTGL zu vergleichen wurde das Programm `graphletAnalyser` genutzt und erweitert. Es wurde bereits 2013 von *Tatiana Bakirova* im Rahmen ihrer Diplomarbeit im Arbeitskreis *Molekulare Bioinformatik* geschrieben. Die ursprüngliche Funktionalität wurde erweitert. Hierbei wurden Funktionen zur Analyse von Komplexgraphen, Aminosäuregraphen und den Sekundärstrukturgraphen implementiert. Diese Graphen stammen allesamt aus der PTGL (Protein Topology Graph Library) von Tim Schäfer.

### 2.1 PLCC

### 2.2 Die PTGL

### 2.3 Der *Graphlet*-Algorithmus

**Motivation** Die PTGL ermöglicht also die Darstellung von Proteinstrukturtopologien als Graphen. Um aus diesen Graphen weitere Informationen zu gewinnen, ist es sinnvoll, sie untereinander vergleichen zu können. Ein solcher Vergleich ist jedoch ein schwieriges Problem: Gesucht ist eine Funktion  $f : (G, G') \rightarrow \mathbb{R}$ , die für zwei Graphen  $G$  und  $G'$  deren Ähnlichkeit zueinander beziffert. Es gibt diverse Möglichkeiten dieses Problem zu bearbeiten, von denen jedoch keine einfach ist. Eine Möglichkeit ist, die Suche nach größten gemeinsamen isomorphen Teilgraphen in  $G$  und  $G'$ , oder man versucht eine Editierdistanz zu berechnen - also herauszufinden, wie viele Operationen (Hinzufügen oder Entfernen von Knoten und Kanten) nötig sind um  $G$  in  $G'$  zu überführen. Diese beiden genannten Methoden erfordern jedoch aufwändige Berechnungen. Deshalb werden Methoden verwendet, die *Topologische Charakteristiken* berechnen und dies in polynomieller Laufzeit bewerkstelligen. Der Vorteil hierbei ist, dass die (aufwändige) Berechnung dieser Charakteristiken nur einmal pro Graph erfolgen muss. Die Charakteristiken können dann als Datenpunkte verglichen werden und man spart sich die Berechnungen, die man sonst

für alle Paare von Graphen  $G, G'$  durchführen muss. Eine Algorithmus, mit dem sich solche Charakteristiken verechnen lassen wurde 2009 von *N. Shervashidze* vorgestellt: Der *Graphlet*-Algorithmus.

**Beschreibung des Algorithmus** *Graphlets* sind kleine induzierte Teilgraphen eines größeren ungerichteten Graphen. *N. Shervashidze* stellte diese Methode als Vergleichsschema für Graphen 2009 zum ersten Mal vor. (Literaturverweis einfügen). Folgendes Bild zeigt alle *Graphlets* der Größe 4:




Abbildung 2.1: Graphlets der Größe 4 (*Shervashidze et al.*)

Um ein *Graphlet* der Größe  $k$  zu finden, besucht der Algorithmus alle Euler-Wege der Länge  $k$ , in dem gegebenen Graphen. Für jeden dieser Wege überprüft er, für alle Paare von Knoten  $v, w$  ob es eine Kante  $e = v, w$  gibt, die nicht zu dem besuchten Euler-Weges gehört. Je nachdem, welche Kanten hierbei gefunden werden, wird der Zähler für das entsprechende *Graphlet* erhöht. Der Algorithmus zählt hier aber nur alle zusammenhängenden *Graphlets*. Er verwendet die folgenden Gewichtungsvektoren:

## Graphlet-Gewichtungsvektoren

$$w_2 := \begin{pmatrix} 1 \\ 2 \end{pmatrix} \quad (2.1a)$$

$$w_3 := \begin{pmatrix} 1 & 1 \\ 6 & 2 \end{pmatrix} \quad (2.1b)$$

$$w_4 := \begin{pmatrix} \frac{1}{24}, \frac{1}{12}, \frac{1}{4}, 1, \frac{1}{8}, \frac{1}{2} \end{pmatrix} \quad (2.1c)$$

$$w_5 := \begin{pmatrix} \frac{1}{120}, \frac{1}{72}, \frac{1}{48}, \frac{1}{36}, \frac{1}{28}, \frac{1}{20}, \frac{1}{14}, \frac{1}{10}, \frac{1}{12}, \frac{1}{8}, \frac{1}{4}, \frac{1}{2}, \frac{1}{12}, \frac{1}{12}, \frac{1}{4}, \frac{1}{4}, \frac{1}{2}, 1, \frac{1}{2}, 1 \end{pmatrix} \quad (2.1d)$$

Jede Stelle eines Vektors  $w_i$  ist mit einem *Graphlet* assoziiert. Da der Algorithmus alle Euler-Wege einer Länge  $i$  in dem Graphen abläuft, sind in den Vektoren Brüche eingetragen, wobei der Zähler für die Anzahl der Euler-Wege der Länge  $i$  steht. Dies stimmt natürlich nicht für die sogenannten Stern-*Graphlets* ( $g_4$  in 2.1  $g_{19}, g_{20}$  und  $g_{21}$  in 3.3). Da diese keinen Euler-Weg der Länge 4 bzw. 5 enthalten werden sie anders gezählt. (beispiel mit Pseudocode einfügen?)

## 2.4 graphletAnalyser

Der **graphletAnalyser** berechnet die oben beschriebenen *Graphlets* nach dem Algorithmus von *Shervashidze et al.*. Zur Zeit unterstützt er die Berechnung für 3 verschiedene Graphen der PTGL: SSE-Graphen sind Graphen, die eine Polypeptidkette als Graph darstellen indem sie ihre Sekundärstrukturelemente als Knoten repräsentieren und diese mit Kanten verbinden, wenn sie räumlich benachbart sind.

Komplexgraphen sind Graphen für Proteinkomplexe; sie modellieren mehrere Polypeptidketten indem sie mehrere SSE-Graphen miteinander verknüpfen.

Aminosäuregraphen modellieren einzelne Aminosäuren als Knoten und verbinden diese miteinander, wenn sie räumlich benachbart sind. Dementsprechend ein Vielfaches der Knoten und Kanten eines SSE- oder Komplex-Graphen.

Zusätzlich zu den *Graphlets* bis zur Größe 5 berechnet der **graphletAnalyser** markierte *Graphlets* mit bis zu 3 Knoten. Dabei werden zunächst alle Markierungen die kombinatorisch möglich sind berechnet und die entsprechenden *Graphlets* werden gezählt.

## 2.5 Scoring

### 2.5.1 Tanimoto-Koeffizient

### 2.5.2 Relative *Graphlet*-Häufigkeiten-Distanz

### 2.5.3 *Root-Mean-Square-Deviation*

## 2.6 Datensätze

### 2.6.1 FATCAT-SCOP-*Benchmarking-Set*

Die FATCAT SCOP DB, beschrieben in: <http://bioinformatics.oxfordjournals.org/content/23/2/e219.long> könnte sich gut zum Vergleich eignen

Das FATCAT-SCOP-*Benchmarking-Set* ist für das Programm FATCAT zusammengestellt worden, um seine Performance mit der von etablierten Strukturalignment-Programmen wie DALI und CE zu vergleichen. Der Datensatz setzt sich aus über 13000 PDB-Einträgen zusammen. Er ist nach Paaren mit großer struktureller Ähnlichkeit sortiert. So eignen sich auch Teilmengen des Datensatzes, um *Graphlets* zu testen. Wenn der Ansatz funktioniert, dann sollten die Paare aus dem FATCAT-Datensatz auch in der PTGL die Paare mit dem höchsten Score sein.

### 2.6.2 Fallstudien

## 2.7 Ergebnisse

## 2.8 Diskussion und Ausblick

Es bieten sich Paper an, die in Liisa Holm *Advances and Pitfalls of Protein Structure Prediction* besprochen wurden. Das Problem ist, dass **graphletAnalyser** Vektoren erzeugt - also eindimensionale Daten. Somit eignen sich Methoden, die 2D- oder 3D-Daten miteinander alignieren schlecht zum Vergleich. *Holm* erwähnt in ihrer Arbeit aber auch Autoren, die Vergleiche von eindimensionalen Daten durchgeführt haben. Dies sind folgende:

Liu X, Zhao YP, Zheng WM: CLEMAPS: multiple alignment of protein structures based on conformational letters

Sierk ML, Pearson WR: Sensitivity and selectivity in protein structure comparison

Sacan A, Toroslu IH, Ferhatosmanoglu H: Integrated search and alignment of protein structures

Friedberg I, Harder T, Kolodny R et al. Using an alignment of fragment strings for comparing protein structures

Tung CH, Huan JW, Yang JM: Kappa-alpha plot derived structural alphabet and BLOSUM-like substitution matrix for rapid search of protein structure database

Yang JA: Comprehensive description of protein structures using protein shape code



# Kapitel 3

## Anhang

### 3.1 Tabellenverzeichnis

### 3.2 Bildverzeichnis




Abbildung 3.1: Graphlets der Größe 3 (*Shervashidze et al.*)

### 3.3 Literaturverzeichnis




Abbildung 3.2: Graphlets der Größe 4 (*Shervashidze et al.*)




Abbildung 3.3: Graphlets der Größe 5 (*Shervashidze et al.*)



Abbildung 3.4: UML-Diagramm von graphletAnalyser