

Bioinformatische Anwendung von *Graphlets* zur
Analyse von Proteinstrukturtopologien zur
Analyse von Proteinen
Rohfassung

Ben Haladik

1. März 2016

Inhaltsverzeichnis

1	Einleitung	3
1.1	Motivation	3
1.2	<i>State of the Art</i>	3
1.3	Ziele	5
1.4	Aufbau der Arbeit	5
2	Materialien und Methoden	6
2.1	PTGL	6
2.2	PLCC	6
2.3	Der <i>Graphlet</i> -Algorithmus	7
2.4	<code>graphletAnalyser</code>	8
2.5	Ähnlichkeitsmaße	9
2.5.1	Relative <i>Graphlet</i> -Häufigkeiten-Distanz	9
2.5.2	Modifizierter Jaccard-Index	10
2.6	Datensätze	11
2.6.1	Fallstudien - Datensatz 1	11
2.6.2	Fallstudien - Datensatz 2	11
2.6.3	Fallstudien - Datensatz 3	12
3	Ergebnisse	13
3.1	Erweiterung von <code>graphletAnalyser</code>	13
3.2	Bewertungsfunktionen in PLCC	13
3.3	Der <i>Graphlet</i> -Worte-Algorithmus	13
3.4	Fallstudien - Datensatz 1	15
3.5	Fallstudien - Datensatz 2	16
3.6	Fallstudien - Datensatz 3	16
4	Diskussion und Ausblick	17
4.1	Diskussion	17
4.1.1	Datensatz 1	17
4.1.2	Datensatz 2	19
4.1.3	Datensatz 3	19
4.2	Ausblick	19
4.2.1	Optimierung der Laufzeit von <code>graphletAnalyser</code>	19

4.2.2	Ähnlichkeitssuche	19
4.2.3	<i>Graphlets</i> im Faltungsraum	19
4.2.4	<i>Graphlet</i> -Motive	19
5	Anhang	20
5.1	Bildverzeichnis	20
5.2	Tabellenverzeichnis	21

Kapitel 1

Einleitung

1.1 Motivation

TODO: Zitationen einfügen: schwierigkeit der Analyse, bereits bekannte Methoden
TODO: strkerer Bezug auf und nennung von tatianas arbeit (insbesondere bio-graphlets)
TODO: Bereits bekannte Anwendungen von Graphlets: Anwendung von Shervashidze auf ZUSAMMENHAENGENDE graphen, zeigt Probleme mit der Darstellung in der PTGL - einzelne Knoten werden nur in marginaler Weise integriert. Anwendung von Przulj: Grosse Netzwerke . Vergleich mit zufälligen Graphen. Vergleich zwischen PPIs mit hoher Praezision und PPIs mit niedriger praezision. betrifft ebenfalls nur vollstaendige graphen. datensatz von dobson und doig (in shervashidze arbeit erwaeht) verwendet svms zur analyse - 70 prozent genauigkeit wurde erreicht. dies ist ein anzeichen dafür, dass die Klassifizierung mit vektoren nur begrenzt genutzt werden kann. (shervashidze ergebnis ist auch nicht viel besser) es ist zu erwähnen, dass SVMs zu den fortgeschrittensten Klassifizierungsmethoden gehören, die zur zeit verwendet werden.

Proteine sind gewissermaßen die Werkzeuge der Zelle. Fast jede Aufgabe die sie bewältigen muss, um zu überleben, löst sie mit Hilfe von Proteinen. Dementsprechend vielfältig sind die Formen und Funktionen, die Proteine annehmen - und wie bei Werkzeugen auch, folgt die Form der Funktion. Die Aufklärung der dreidimensionalen Struktur von Proteinen ist somit für ein tiefergehendes Verständnis ihrer Funktion von zentraler Bedeutung.

Im Rahmen der

Graphlets sind kleine vollständige induzierte Teilgraphen.

1.2 *State of the Art*

TODO: Methoden nennen, weitere Zitationen

Es gibt bereits einige Methoden, um Proteinstrukturen miteinander zu vergleichen. *Hasegawa et al* [1] liefern einen umfangreichen Vergleich verschiedener Methoden, bei denen Strukturen auf unterschiedlichen Abstraktionsstufen betrachtet und verglichen werden. So können Proteinstrukturen dreidimensional, zweidimensional und eindimensional betrachtet und verglichen werden.

3D-Methoden versuchen zunächst mittels Sequenzalignment einen Bereich in den zu vergleichenden Proteinen zu finden, in dem sich beide Proteine sehr ähnlich sind. Dieser Bereich fungiert gewissermaßen als *Anker* für das weitere Alignment. In den weiteren Schritten werden die Proteine so positioniert, dass die Distanzen in dem alignierten Bereich minimal sind. Von diesem *Template* ausgehend, werden die Distanzen zwischen den weiteren Residuen der Proteine berechnet und meist mittels *Root-mean-square-deviation* bewertet.

2D-methoden versuchen Kontakte zwischen Residuen oder Sekundärstrukturen zu vergleichen. Diese Kontakte werden beispielsweise als graphen oder Distanzmatrizen dargestellt. Der Vergleich zwischen zwei Proteinstrukturen wird dann beispielsweise als Vergleich zweier Distanzmatrizen durchgeführt.

1D-Methoden nutzen Strukturprofile zur Darstellung von Proteinen. In Strukturprofilen repräsentieren einzelne Buchstaben Eigenschaften von Residuen und die Konformation des Protein-*Backbone* an der entsprechenden Stelle. So können schnelle *String*-Algorithmen genutzt werden, um Strukturen zu suchen und zu vergleichen.

0D-Methoden reduzieren die 3D-Struktur am stärksten. Die gesamte Struktur wird durch eine Zahl beschrieben, die sich aus der Struktur berechnen lässt. Sie erlauben sehr schnelle Suchen in Datenbanken, haben aber das Problem, dass sie keinen Vergleich von Teilstrukturen ermöglichen.

Die Methoden stellen alle einen Versuch dar, die Ähnlichkeit von Proteinen zu beziffern. Sie werden angewendet, um entfernt homologe Proteine aufzuspüren und in Datenbanken eine Ähnlichkeitssuche zu ermöglichen. Dies findet vor allem im pharmakologischen Bereich Anwendung.

Interessant ist, dass unter den von *Hasegawa et al* vorgestellten 1D-Methoden keine wirklich analog zur Analyse mit *Graphlets* funktioniert. Andere 1D-Methoden versuchen die Polypeptidkette als *String* darzustellen und damit die Konformationsänderung des *Backbone* zu beschreiben. Im Gegensatz dazu zählt der *Graphlet*-Algorithmus die *Graphlets* unabhängig von ihrer Position im Graphen. Somit repräsentiert der *Graphlet*-Vektor an jeder Stelle eine globale Eigenschaft des Graphen, anstatt die Veränderung von einer Sekundärstruktur zur nächsten zu beschreiben.

Des weiteren sind die meisten Methoden, die Proteinstrukturen vergleichen, *Template*-basiert. Um den Suchraum einzuschränken muss eine Struktur ausgewählt werden, die als Vorlage für den Vergleich mit anderen Strukturen dient.

Dementsprechend ändert sich das Ergebnis des Vergleichs auch in Abhängigkeit der gewählten Vorlage.

1.3 Ziele

Ziel dieser Arbeit war zunächst die Erweiterung der Funktionalität des **graphletAnalyser**. Hierzu gehört eine funktionierende Datenbankbindung, so dass die *Graphlet*-Vektoren für alle verschiedenen Graphtypen korrekt in die PTGL eingetragen werden können. Die Suche nach markierten *Graphlets* sollte so implementiert werden, dass sie auf Graphen mit beliebigen Markierungen angewandt werden kann. Deshalb wurde ein Algorithmus entwickelt und implementiert, der aus einem Alphabet von Knotenmarkierungen alle Worte berechnet, die markierte 2- und 3-*Graphlets* repräsentieren - der *Graphlet*-Worte-Algorithmus. Schlussendlich sollte im durch Fallstudien überprüft werden, ob und inwiefern sich *Graphlets* eignen, um die Ähnlichkeit von Proteinstrukturtopologien zu untersuchen. Dies wurde mit unterschiedlichen Metriken getestet. Die hierbei errechneten Ähnlichkeitswerte wurden mit den Ergebnissen des *Strukturalignment*-Programms *PDBeFold* [?] verglichen.

1.4 Aufbau der Arbeit

Zunächst wird im Kapitel *Materialien und Methoden* PLCC vorgestellt - das Programm, mit dem die Graphen der PTGL erzeugt werden. Es folgt eine Kurzbeschreibung der PTGL selbst, sowie eine Beschreibung des *Graphlet*-Algorithmus und des *Graphlet*-Worte-Algorithmus. Weiterhin wird das Programm **graphletAnalyser** vorgestellt, welches den *Graphlet*-Algorithmus implementiert. Anschließend werden verschiedene Metriken vorgestellt, mit denen die erhaltenen *Graphlet*-Vektoren verglichen werden. Die Ergebnisse dieses Vergleichs werden im Teil Ergebnisse und Diskussion vorgestellt. Hierbei werden die verschiedenen Metriken verglichen und es wird überprüft inwiefern die Suche nach markierten *Graphlets* zu diesem Ergebnis beiträgt.

Kapitel 2

Materialien und Methoden

Um die Proteinstrukturtopologien aus der PTGL zu vergleichen wurde das Programm `graphletAnalyser` genutzt und erweitert. Es wurde bereits 2013 von *Tatiana Bakirova* im Rahmen ihrer Diplomarbeit im Arbeitskreis *Molekulare Bioinformatik* geschrieben. Die ursprüngliche Funktionalität wurde erweitert. Hierbei wurden Funktionen zur Analyse von Komplexgraphen, Aminosäuregraphen und den Sekundärstrukturgraphen implementiert. Diese Graphen stammen allesamt aus der PTGL (Protein Topology Graph Library) von Tim Schäfer.

2.1 PTGL

Die Protein Topology Graph Library entstand aus einer Idee von Patrick May und Ina Koch [2]. Ausgehend von der Tatsache, dass sich Proteinstrukturtopologien als räumliche Beziehungen von SSEs untereinander definieren lassen, verwendet die PTGL *Graphen*, um Proteinstrukturtopologien darzustellen. Hierbei stellen die Knoten des Graphen die SSEs eines Proteins dar. Sie werden dem jeweiligen SSE entsprechend markiert. Knoten, die α -Helices repräsentieren werden mit einem H markiert, β -Faltblätter mit einem E. Weiterhin ermöglicht die PTGL die Darstellung von Liganden, ([5]) denen mit L markierte Knoten zugeordnet werden. Um die räumliche Nachbarschaft von Sekundärstrukturen und Liganden untereinander darstellen zu können werden ungerichtete Kanten zwischen Knoten gezogen wenn die entsprechenden Elemente benachbart sind. Jede Polypeptidkette eines Proteins wird dann als *Proteingraph* dargestellt. Die Zusammenhangskomponenten eines Proteingraphen werden als Faltungsgraphen bezeichnet, weil sie typischerweise eine unabhängige Faltungseinheit darstellen.

Durch diese abstrahierte Darstellung können zentrale Charakteristika eines Proteins wie Motive und Domänen einfach visualisiert werden.

2.2 PLCC

PLCC ist die *Software*, die die Daten der PTGL generiert und verwaltet.

Die Berechnung der Graphen der PTGL erfolgt unter Verwendung der entsprechenden PDB und DSSP Dateien. Um den Graphen für eine Polypeptidkette zu berechnen werden aus der DSSP-Datei die Sekundärstrukturelemente (SSEs) des Proteins ausgelesen. Für jedes Paar von SSEs wird die Anzahl der räumlichen Kontakte ihrer Residuen berechnet. Wenn die Anzahl dieser Kontakte einen gewissen Grenzwert überschreitet, wird angenommen, dass diese SSEs räumlich benachbart sind und die jeweiligen Knoten werden durch eine Kante verbunden. So wird für jede Polypeptidkette ein Graph erstellt.

Komplexgraphen werden ebenfalls in dieser Arbeit untersucht. Ihre Berechnung erfolgt analog zur Berechnung der Proteingraphen. Der Unterschied besteht darin, dass ein Komplexgraph mehrere Polypeptidketten beschreibt.

Aminosäuregraphen werden ebenfalls untersucht und analog zu Proteingraphen berechnet. Hier werden keine SSEs betrachtet. Stattdessen repräsentiert jeder Knoten eine Aminosäure eines Proteins. Die Knoten werden entsprechend der chemischen Eigenschaften der Aminosäuren markiert. Knoten, die saure oder basische Residuen darstellen werden mit einem c markiert. Ein p markiert Knoten für polare Residuen, die weder sauer noch basisch sind. Für unpolare Aminosäuren wird ein h verwendet. Auch Liganden können in Aminosäuregraphen dargestellt werden. Ihre Knoten werden durch ein ? markiert.

Weiterhin ermöglicht PLCC den Vergleich von *Graphlet*-Vektoren, die im folgenden Teil vorgestellt werden. Diese werden mit der von *Prülic et al.* [3] vorgestellten Relativen-*Graphlet*-Häufigkeiten-Distanz verglichen.

2.3 Der *Graphlet*-Algorithmus

Um die Graphen der PTGL vergleichen zu können werden *Graphlets* verwendet. Diese sind im Gegensatz zu Graph-Isomorphismen in polynomieller Zeit berechenbar [?]. *Graphlets* sind kleine, induzierte, zusammenhängende Teilgraphen mit bis zu 5 Knoten. Die Abbildungen 5.1, 5.2 und 5.3 zeigen die *Graphlets* mit 3, 4 und 5 Knoten. Sie werden durch den Algorithmus gezählt, so dass anstatt von Graphen nur noch Vektoren mit den *Graphlet*-Häufigkeiten verglichen werden. Ein solcher Vergleich von Vektoren ist in konstanter Zeit möglich.

Beschreibung des Algorithmus Um alle *Graphlets* der Größe $k \in \{3, 4, 5\}$ zu zählen werden alle Euler-Wege der Länge $k - 1$ in dem gegebenen Graphen gesucht. Für jeden gefundenen Euler-Weg, werden alle inzidenten Kanten aller Knoten des Weges überprüft. Wird hierbei ein *Graphlet* gefunden, wird der Zähler für das entsprechende Graphlet um den Wert an der entsprechenden Stelle der unten stehenden Gewichtungsvektoren w_k erhöht.

Für *Graphlets* mit $k \geq 4$ existieren zusätzlich die sogenannten Stern-*Graphlets* (g_4 in 5.2, sowie g_{19}, g_{20} und g_{21} in 5.3), die keinen solchen Euler-Weg enthalten. Ein Stern-*Graphlet* mit k -vielen Knoten hat genau k -viele Kanten und keinen Euler-Weg der Länge $k - 1$.

Graphlet-Gewichtungsvektoren

$$w_2 := \left(\frac{1}{2} \right) \quad (2.1a)$$

$$w_3 := \left(\frac{1}{6}, \frac{1}{2} \right) \quad (2.1b)$$

$$w_4 := \left(\frac{1}{24}, \frac{1}{12}, \frac{1}{4}, 1, \frac{1}{8}, \frac{1}{2} \right) \quad (2.1c)$$

$$w_5 := \left(\frac{1}{120}, \frac{1}{72}, \frac{1}{48}, \frac{1}{36}, \frac{1}{28}, \frac{1}{20}, \frac{1}{14}, \frac{1}{10}, \frac{1}{12}, \frac{1}{8}, \frac{1}{4}, \frac{1}{2}, \frac{1}{12}, \frac{1}{12}, \frac{1}{4}, \frac{1}{4}, \frac{1}{2}, 1, \frac{1}{2}, 1 \right) \quad (2.1d)$$

Jede Stelle eines Gewichtungsvektors w_k ist mit einem *Graphlet* assoziiert. Die Nenner der Brüche in den Vektoren entsprechen den Anzahlen der Euler-Wege der Länge $k - 1$ in den entsprechenden *Graphlets*. Wenn alle Euler-Wege eines *Graphlets* besucht wurden und der zugehörige induzierte Teilgraph ihm entspricht wird sein Zähler ganzzahlig und das *Graphlet* gilt als gefunden. Hierbei bilden die Stern-*Graphlets*, die keine Euler-Wege der Länge $k - 1$ enthalten natürlich die Ausnahme.

Somit wird jedes *Graphlet* gezählt und die entsprechende Anzahl wird in einen Vektor geschrieben. Die so erzeugten Vektoren werden im folgenden als *Graphlet*-Vektoren bezeichnet. Da wir 29 verschiedene *Graphlets* betrachten hat ein *Graphlet*-Vektor 29 Stellen. Für den Vergleich von Proteinstrukturen bedeutet dies, das sich der Berechnungsaufwand auf $O(1)$ reduziert, da anstatt von Graphen oder dreidimensionalen Körpern Vektoren im Vektorraum \mathbb{R}^{29} verglichen werden.

TODO: Pseudocode in Anhang einfügen

2.4 graphletAnalyser

In seiner ursprünglichen Version wurde das Programm bereits 2013 von *Tatiana Bakirova* geschrieben. Im Sommer 2015 wurde es um einige Funktionen erweitert.

`graphletAnalyser` ist in C++ geschrieben. Zur internen Darstellung der Graphen wird die *Boost-Graph-Library* verwendet. Die Datenbankanbindung wird mittels der Bibliothek `pqxx` realisiert.

Als Input erhält das Programm eine oder mehrere GML-Dateien, die Graphen darstellen. Aus jeder GML-Datei wird mit der *Boost-Graph-Library* intern ein Graph erstellt, der für die Berechnungen verwendet wird.

Für den eingelesenen Graphen berechnet das Programm alle *Graphlets* der Größen 3, 4 und 5. Die Implementierung entspricht der Matlab-Implementierung

von *N. Shervashidze* [?]. Zusätzlich berechnet es markierte *Graphlets* der Größen 2 und 3, wobei die Markierungen den SSE-Zuordnungen der PTGL entsprechen. Es gibt 35 verschiedene markierte *Graphlets* mit 2 oder 3 Knoten. Unter Berücksichtigung der Markierungen erhöht sich die Anzahl der Stellen der *Graphlet*-Vektoren damit auf 64. Die Knotengradverteilungen können ebenfalls berechnet werden.

Der Output des Programms umfasst zum einen die Ausgabe der *Graphlet*-Vektoren mit oder ohne markierte *Graphlets* in den Formaten csv, matlab und nova. Zusätzlich können die *Graphlet*-Vektoren in einer Datenbank, die zuvor mit PLCC erstellt wurde gespeichert werden. Die Knotengradverteilung kann zusammen mit anderen Daten eines Graphen als .csv-Datei ausgegeben werden.

2.5 Ähnlichkeitsmaße

Durch die Verwendung der *Graphlets* wird der direkte Vergleich von Graphen durch einen Vergleich von *Graphlet*-Vektoren ersetzt. Für den Vergleich dieser Vektoren gibt es prinzipiell zwei verschiedene Möglichkeiten. Entweder kann man eine Abstandsmessung durchführen, oder man zählt die gemeinsamen Elemente der beiden Vektoren.

2.5.1 Relative *Graphlet*-Häufigkeiten-Distanz

N. Pržulj et al. haben *Graphlets* bereits in verschiedensten Zusammenhängen auf biologische Daten wie Protein-Protein-Interaktionsnetzwerke [3] angewandt. Als Maß für die Ähnlichkeit von Netzwerken nutzen sie die Relative-*Graphlet*-Häufigkeiten-Distanz (RGF) $D(G, H)$. Diese Metrik berechnet den Abstand zwischen zwei Graphen G und H als logarithmierte Differenz der normalisierten Anzahl der *Graphlets* in G und H . Sie ist folgendermaßen definiert:

Sei $N_i(G)$ die Anzahl der *Graphlets* von Typ $i \in 1, \dots, 29$ und $T(G) = \sum_{i=1}^{29} N_i(G)$ die Anzahl der *Graphlets* in G , beziehungsweise H

Dann ist die Relative-*Graphlet*-Häufigkeiten-Distanz $D(G, H)$ für zwei Graphen G und H definiert als:

$$D(G, H) := \sum_{i=1}^{29} |F_i(G) - F_i(H)| \quad (2.2a)$$

$$\text{mit } F_i(G) := -\log\left(\frac{N_i(G)}{T(G)}\right) \quad (2.2b)$$

Diese Metrik lässt sich analog zur euklidischen Distanz auffassen, denn sie berechnet für jeden Index i die Differenz zwischen den Stellen x_i, y_i zweier Vektoren x und y . Sie verwendet die normalisierten *Graphlet*-Vektoren unter der

Annahme, dass die Ähnlichkeit zweier Netzwerke sich aus der Ähnlichkeit lokaler Substrukturen ableiten lässt [3]. Somit können Netzwerke, die ähnliche Substrukturen haben, sich aber in ihrer Größe stark unterscheiden, immer noch als ähnlich erkannt werden. Zusätzlich soll durch diese Normalisierung ausgeschlossen werden, dass einzelne besonders häufige *Graphlets* die Messung verzerren.

Da alle Einträge der Vektoren aus dem Intervall $[0, 1] \in \mathbb{R}$ stammen werden sie logarithmiert. Damit erhält man Abstände, die aus deutlich größeren Intervallen stammen. Die Ergebnisse können so leichter interpretiert werden und der Einfluss der von Rundungsfehlern verkleinert sich.

Weiterhin wurde gezeigt, [3] dass diese Metrik auch bei verrauschten Daten noch sehr gut funktioniert. Hierbei ist jedoch zu beachten, dass sie bisher vor allem für sehr große Netzwerke mit mehreren Tausend Knoten und Kanten verwendet wurde. Diese Größe kann von Aminosäuregraphen erreicht werden, wenn sie große Proteinkomplexe modellieren. Proteingraphen und Komplexgraphen sind aber deutlich kleiner.

2.5.2 Modifizierter Jaccard-Index

Der Jaccard-Index ist im eigentlichen Sinne ein Maß, um die Ähnlichkeit von gleichmächtigen Mengen zu bewerten. Für zwei Mengen A, B berechnet sich der Jaccard-Index $D_{Jac}(A, B)$ folgendermaßen:

$$D_{Jac}(A, B) := \frac{\sum_{x \in A \cap B} 1}{\sum_{x \in A \cup B} 1}$$

Dementsprechend sind zwei Mengen A, B gleich, wenn gilt $D_{Jac} = 1$ und disjunkt, wenn gilt $D_{Jac} = 0$. Mit ihm wird die relative Anzahl der Elemente beider Mengen berechnet. Um dieses Maß in sinnvoller Weise auf *Graphlet*-Vektoren zu übertragen wurde ein zusätzlicher Faktor $k \in \mathbb{R}$ mit $k \in [0, 1]$ eingeführt, der als Präzisionsfaktor zu verstehen ist. Die Definition des modifizierten Jaccard-Index $D_{Jac-m}(v, w)$ für zwei Vektoren v, w lautet also:

$$D_{Jac-m}(v, w) := \frac{\sum_{i=1}^n x_i}{\sum_{x \in A \cup B} 1}$$

Hierbei gilt:

$$x_i = \begin{cases} 1 & \text{if } v_i \geq w_i \times k \wedge w_i \geq v_i \times k \\ 0 & \text{else} \end{cases}$$

In dieser modifizierten Variante werden zwei Vektoren v, w als gleich angesehen, wenn sich v_i, w_i für alle i höchstens um den Faktor k unterscheiden. Dies steht im Gegensatz zur RGF, die - analog zu einer Vektornorm - die Abstände zwischen zwei *Graphlet*-Vektoren misst.

2.6 Datensätze

2.6.1 Fallstudien - Datensatz 1

Anfangs wurden 20 verschiedene Proteine aus verschiedenen CATH-Klassen zum Vergleich ausgewählt. Die Proteine wurden so gewählt, dass die drei CATH-Klassen mit vielen Sekundärstrukturelementen *mainly-alpha*, *mainly-beta* und *alpha-beta* vertreten sind. Weiterhin wurde die Auswahl so getroffen, dass es für jede Stufe der Hierarchie mindestens zwei Proteine gibt, die auf der entsprechenden Stufe in die gleiche Klasse eingeordnet werden. Die Proteine werden im folgenden kurz beschreiben.

Zusammengefasst

PDB-ID	CATH-Code
2UTG	1.10.210.10
1VIB	1.10.287.120
1QPU	1.20.120.10
1QQ3	1.20.120.10
2XL6	1.20.120.10
2YL1	1.20.120.10
1rxq	1.20.120.450
2qe9	1.20.120.450
2RD9	1.20.120.450
1M4R	1.20.1250.10
1HGU	1.20.1250.10
1PV6	1.20.1250.20
1AWR	2.40.100.10
1D9C	1.20.1250.10
1NGL	2.40.128.20
1N7V	2.105.10.10
7TIM	3.20.20.70
1NEY	3.20.20.70
2V5L	3.20.20.70
1V3Z	3.30.70.100
1A17	1.25.40.10
1ar0	3.10.450.50

2.6.2 Fallstudien - Datensatz 2

Für die ersten Tests wurden verschiedene Proteine entsprechend ihrer CATH-Klassifizierungen zusammengestellt. Die Proteine wurden so gewählt, dass die 3 CATH-Klassen gleich stark vertreten sind, in denen sich viele Sekundärstrukturelemente befinden. Dementsprechend wurden Proteine aus der CATH-Klasse 4 ignoriert. Diese Klasse enthält nur Proteine mit wenigen Sekundärstrukturelementen.

Es befinden sich je 5 Vertreter der drei CATH-Klassen 1 (*mainly-alpha*), 2 (*mainly-beta*) und 3 (*alpha-beta*) in diesem Datensatz. Diese wurden so gewählt, dass je ein Paar innerhalb der selben Klasse ein direkter struktureller Nachbar mit einer Sequenzidentität von mehr als 95%, sowie ein Nachbar mit einer Sequenzidentität von mehr als 35% befindet, um zu überprüfen, ob die *Graphlet*-Vektoren von Aminosäuregraphen eine Korrelation mit der Sequenzidentität aufweisen können. Weiterhin wurde je ein Vertreter der selben Topologie aus einer anderen Superfamilie, sowie der selben Architektur mit anderer Topologie gewählt.

Da die *Graphlet*-Vektoren globale Eigenschaften eines Graphen beschreiben, wurde bei diesem Datensatz darauf geachtet, dass alle Strukturen aus genau einer Polypeptidkette mit genau einer Domäne bestehen.

Diese Herangehensweise folgt aus der Vermutung, dass einzelne Domänen charakteristische *Graphlet*-Vektoren haben.

PDB-ID	CATH-ID	Klassifizierung
1qpu	1.20.120.10	Elektronentransport
1qq3	1.20.120.10	Elektronentransport
1cgn	1.20.120.10	Elektronentransport
1he9	1.20.120.260	Toxin (Exoenzym)
3gf9	1.20.900.10	Endocytose
1exs	2.40.128.20	Lipid bindendes Protein
1ngl	2.40.128.20	Transport Protein
1qqs	2.40.128.20	Zucker bindendes Protein
3slo	2.40.128.130	Protein Transport
1wjx	2.40.280.10	RNA-bindendes Protein
5chy	3.40.50.2300	Signaltransduktion
2id9	3.40.50.2300	Signal Protein
3i42	3.40.50.2300	unbekannte Funktion
1d4o	3.40.50.1220	Oxidoreductase
2w0i	3.40.20.10	Transferase

Vergleich von Proteinen ähnlicher Größe

Da *Graphlets* in den Experimenten von Pruzlj et al und Shervashidze et al auf große Graphen angewandt wurden, bietet es sich an, sie auch auf große Proteinkomplexe anzuwenden und bei kleinen Proteinen den Aminosäuregraphen zu verwenden. So kann man (hoffentlich) das Problem der dünn besetzten Graphen umgehen und für verschiedene Größen von Graphen relevante Ergebnisse erzielen. Dafür muss ein Datensatz aus großen Proteinkomplexen mit bekannter struktureller Ähnlichkeit zusammengestellt werden.

2.6.3 Fallstudien - Datensatz 3

Kapitel 3

Ergebnisse

3.1 Erweiterung von graphletAnalyser

Das Einlesen von Komplexgraphen und Aminosäuregraphen ist implementiert worden. Die entsprechenden Alphabete sind im Programmcode vordefiniert und können vom Nutzer über Parameter ausgewählt werden.

Nutzerdefinierte Knotenmarkierungen können nun in der Konfigurationsdatei angegeben werden. Der Nutzer kann ein Alphabet von Knotenmarkierungen und ein *Label* unter dem diese Knotenmarkierungen in den GML-Dateien abgelegt sind angeben. Für dieses Alphabet werden alle äquivalenten *Graphlet*-Worte durch den *Graphlet*-Worte-Algorithmus berechnet. Diese werden dann bei der Berechnung der markierten *Graphlets* im Graphen unter dem vorgegebenen *Label* gesucht und gezählt. Es können also beliebige Alphabete und *Labels* angegeben werden, so lange die Markierungen der Knoten nicht mehr als einen Buchstaben enthalten.

Die Datenbankbindung wurde um Funktionen zum Speichern von Aminosäuregraphen und Komplexgraphen erweitert. Das Speichern von Vektoren markierter *Graphlets* wurde implementiert.

3.2 Bewertungsfunktionen in PLCC

3.3 Der *Graphlet*-Worte-Algorithmus

In der letzten Version von **graphletAnalyser** war es bereits möglich markierte *Graphlets* mit 2 und 3 Knoten in Proteingraphen zu zählen. Diese Funktionalität wurde im Rahmen dieser Arbeit verallgemeinert, so dass der Nutzer beliebige Alphabete angeben kann. Der Algorithmus erhält das Alphabet $\Sigma = \{\sigma_i : i \in \mathbb{N}\}$ der Knotenmarkierungen. Aus diesem Alphabet berechnet er Worte w , die zur

Repräsentation der markierten *Graphlets* genutzt werden. Hierbei können verschiedene Worte das gleiche *Graphlet* repräsentieren. Im Falle von 2-*Graphlets* repräsentieren die zwei Worte (σ_i, σ_j) und (σ_j, σ_i) das gleiche markierte *Graphlet* mit den Knotenmarkierungen σ_i, σ_j . Worte, die das gleiche *Graphlet* repräsentieren, werden im Folgenden als *äquivalente Graphlet-Worte* bezeichnet.

Die Berechnung der äquivalenten *Graphlet*-Worte der Länge 2 ist trivial. Aus dem Alphabet Σ werden alle Worte $w = (\sigma_i, \sigma_j)$ berechnet, wobei Spiegelungen nicht mit ausgegeben werden, da zwei Worte (σ_j, σ_i) und (σ_i, σ_j) äquivalente *Graphlet*-Worte sind.

Die Berechnung aller äquivalenten *Graphlet*-Worte der Länge 3 ist komplizierter, da sie für zwei verschiedene *Graphlets* berechnet werden müssen. Für das *Graphlet* g_1 sind alle Worte äquivalent zueinander, die zyklische Vertauschungen voneinander sind. Für das *Graphlet* g_2 sind Worte äquivalent zueinander, die Spiegelungen voneinander sind (siehe Abbildung 5.1).

Pseudocode Platzhalter

Pseudocode Platzhalter
Pseudocode Platzhalter
Pseudocode Platzhalter
Pseudocode Platzhalter
Pseudocode Platzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter
Pseudocode PLatzhalter

Der Algorithmus besteht aus 3 *for*-Schleifen, die über das Alphabet iterieren. In der äußersten Schleife werden Worte hinzugefügt, in denen alle Buchstaben gleich sind. In der zweiten Schleife wird jeweils der nächste Buchstabe des Alphabets betrachtet. Für jedes Paar a, b von Buchstaben über einem Alphabet Σ sind die Mengen der äquivalenten Worte für das *Graphlet* g_1 $P_{3-Kreis} = \{\}$ und $P_{3-Weg} = \{aaa, aba, aab, abb\}$ für das *Graphlet* g_2

TODO: Beschreibung der Mengen, Beweis

Für das Alphabet der SSE- und Komplexgraphen $\sum_{SSE} := \{H, E, L\}$ und das Alphabet der Aminosäuregraphen $\sum_{AA} := \{h, p, c, ?\}$ gibt der oben beschriebene Algorithmus die folgenden Listen aus:

$$p_2 := (HH, HE,$$

(3.1a)

$$p_{3-Weg} := (HHH, HEH, HHE, HEE, EHE, HEL, LHE, ELH, HLH, HHL, HLL, LHL, EEE, ELE, EEL,$$

(3.1b)

$$p_{3-Kreis} := (HHH, HEH, HEE, HEL, LEH, HLH, HLL, EEE,$$

(3.1c)

(3.1d)

Die Vektoren a_2 , a_{3-Weg} und $a_{3-Kreis}$ beschreiben die Worte für *Graphlets* in AA-Graphen

(3.2a)

$$a_{3-Weg} := (hhh, hph, hhp, hpp, php, hpa, ahp, pah, hp?, ?hp, p?h, hah, hha, haa, aha, ha?, ?ha, a?h, h?h, hh?, h??,$$

(3.2b)

$$a_{3-Kreis} := (hhh, hph, hpp, hpa, aph, h$$

(3.2c)

3.4 Fallstudien - Datensatz 1

Die paarweisen RGF-Distanzen der Proteine befinden sich in den Tabellen ?? und ?. Die paarweisen Jaccard-Indizes befinden sich in den Tabellen ??, ?? und ?. Hierbei wurden die Zellen, die die 4 besten Bewertungen für das Protein der entsprechenden Zeile enthalten grün eingefärbt. Hierbei gilt, dass das Grün umso dunkler ist, je stärker die Ähnlichkeit bewertet wird.

Der Vergleich mittels RGF zeigt für die Aminosäuregraphen die stärksten Ähnlichkeiten immer innerhalb der entsprechenden CATH-Klassen. Sowohl die Proteine aus der *mainly-alpha*-Klasse, als auch die Proteine der *mainly-beta*-Klasse haben die besten Ähnlichkeitswerte mit Proteinen der gleichen Klasse. Innerhalb der Klasse der *alpha-beta*-Proteine, gibt es mit 2id9 und 1d4o zwei Proteine, denen eine größere Ähnlichkeit zu Proteinen der *mainly-alpha*-Klasse attestiert wurde. Bei 1d4o fällt auf, dass der niedrigste Wert mit 7,091 deutlich höher ist, als die besten Werte aller anderen Proteine. 2id9 hat laut der RGF-Distanz die größte Ähnlichkeit zu 1he9. Bis auf diese beiden Ausnahmen lässt sich jedoch eine große starke Korrelation mit den CATH-Klassen erkennen. Alle anderen Proteine haben mindestens die zwei kleinsten zwei RGF-Distanzen zu Vertretern aus der selben CATH-Klasse.

Dies gilt für die Aminosäuregraphen. Die RGF-Distanzen der Proteingraphen zueinander zeigen ein weniger klares Bild. Für die *mainly-alpha*-Klasse und die der *mainly-beta*-Klasse befinden sich die Proteine mit den kürzesten Distanzen immer noch in der selben Klasse. Dies lässt sich für die Proteine der *alpha-beta*-Klasse aber nicht mehr behaupten. Hier haben 2ID9, 3I42 und 2W0I die kürzesten Distanzen zu Proteinen anderer Klassen.

Bei den Komplexgraphen ist die Korrelation zwischen der RGF-Distanz und der Zugehörigkeit zur CATH-Klasse noch geringer. Die Tabelle ?? zeigt nur für die Proteine 1QQ3, 1HE9, 1EXS und 1QQS die kürzeste Distanz zu einem Vertreter der gleichen Klasse. Es fällt jedoch auf, dass besonders häufig die Proteine der *alpha-beta*-Klasse 5CHY, 2ID9 und 3I42 als ähnlich zu anderen bewertet werden.

Der Vergleich der Jaccard-Indizes zeigt ein ähnliches Bild, wie der Vergleich der RGF-Distanzen. Bei den Aminosäuregraphen zeigt sich, dass innerhalb der *mainly-alpha*-Klasse wieder die paarweisen Ähnlichkeiten der *mainly-alpha*-Proteine am größten sind. Dies gilt bis auf eine Ausnahme auch für die *mainly-beta*-Proteine. Das Protein mit der PDB-ID 1NGL wird als strukturell ähnlichstes Protein zu 2W0I bewertet. In der Klasse der *alpha-beta*-Proteine gibt es mit 2ID9 und 1D4O wieder zwei Ausreißer, die die größten paarweisen Ähnlichkeiten nicht zu Vertretern der eigenen Klasse haben. Für 2ID9 wird 1HE9 als ähnlichstes Protein angegeben und 1D4O wird 1QQS zugeordnet.

Die paarweisen Tanimoto-Koeffizienten der Proteingraphen zeigen - wie schon bei den RGF-Distanzen - eine geringere Korrelation mit der Zugehörigkeit zu den CATH-Klassen, als die Koeffizienten der Aminosäuregraphen. Es haben zwar wieder mindestens 3 Vertreter jeder Klasse ihren nächsten Nachbarn in der gleichen Klasse, aber es gibt auch einige Proteine, die ihren nächsten Nachbarn außerhalb der eigenen Klasse haben. Hierzu gehören 1D4O, 2W0I (beide *alpha-beta*) und 3GF9 (*mainly-alpha*). Es fällt auf, dass wieder die Proteine mit den PDB-IDs 2ID9 und 3I42 besonders häufig als strukturell ähnlich zu vielen anderen Proteinen bewertet werden.

Für die Komplexgraphen zeigt die Tabelle wieder eine hohe Ähnlichkeit unter den ersten 3 Proteinen 1QPU, 1QQ3 und 1CGN. Auch innerhalb der Klasse *alpha-beta* sind 3 Proteine mit der höchsten paarweisen Ähnlichkeit bewertet worden. Die geringe Anzahl von stark bewerteten Ähnlichkeiten innerhalb der *mainly-beta*-Klasse ist sehr auffällig. 1QQS und 3SLO sind das einzige Paar mit *beta*-Topologie, dessen Ähnlichkeit als groß bewertet wurde.

3.5 Fallstudien - Datensatz 2

3.6 Fallstudien - Datensatz 3

Kapitel 4

Diskussion und Ausblick

4.1 Diskussion

Die folgende Diskussion der Fallstudien widmet sich vor allem der Frage, wieso die Ergebnisse der Ähnlichkeitsvergleiche, sich so stark zwischen den jeweiligen Graphendarstellungen unterscheiden. Des weiteren wird der Zusammenhang zwischen dem Jaccard-Index und der RGF untersucht.

4.1.1 Datensatz 1

Vergleich der Graphformate

Wie schon im Ergebnisteil dargestellt, zeigen die Vergleiche der Aminosäuregraphen den höchsten Konsens mit der Einteilung der Strukturen durch CATH und SCOPe. Eine mögliche Erklärung hierfür ist die Gestalt der Graphen. Bisher wurden *Graphlets* hauptsächlich zur Analyse von zusammenhängenden Graphen verwendet ([?], [?]). Proteingraphen und Komplexgraphen sind jedoch nicht immer zusammenhängend. es kommt häufig vor, dass einzelne Knoten keine Verbindungen zum Rest des Graphen aufweisen. Das unten stehende Bild zeigt ein Beispiel.

Dadurch, dass dies in den zusammenhängenden *Graphlets* nicht berücksichtigt werden kann, geht Information verloren. Unabhängig von der Wahl des Ähnlichkeitsmaß würde dieser Graph mit einem anderen Graphen, dem die beiden Helix-Knoten mit einem Grad von 0 fehlen, als gleich bewertet werden, obwohl dieser zwei SSEs weniger aufwiese. Diese SSEs können jedoch biologisch von zentraler Bedeutung sein.

Im Gegensatz hierzu sind die Aminosäuregraphen dieser Fallstudie zusammenhängend. Dies erklärt die höhere Genauigkeit.




Abbildung 4.1: Proteingraph von 3GF9 - Datensatz 1

Vektor RGF Jaccard-Index

Vergleich der Distanzmaße

Wirft man einen Blick in die Tabellen, sieht es zunächst so aus, als würden sich Jaccard-Index und RGF ähnlich gut eignen, um die Ähnlichkeit der *Graphlet*-Vektoren zu bewerten. Die RGF stellt eine *Distanz* zwischen zwei Vektoren dar. Dementsprechend steht ein RGF-Wert von 0 für die Gleichheit zweier Vektoren, je höher der Wert ist, desto höher ist der Abstand zwischen den beiden Vektoren. Der modifizierte Jaccard-Index, der hier Verwendung findet, zählt Elemente, die sich um höchstens einen Faktor k unterscheiden. Ein RGF-Wert von 1 bedeutete, dass alle Elemente beider Vektoren sich höchstens um den Faktor k unterscheiden. Ein Wert von 0 bedeutet, dass alle Elemente sich um mehr als den Faktor k unterscheiden. Dementsprechend würde man erwarten, dass die *Pearson*-Korrelation von RGF und Jaccard-Index negativ ist. Die folgende Tabelle zeigt jedoch, dass diese für alle berechneten Daten positiv ausfällt.

4.1.2 Datensatz 2

4.1.3 Datensatz 3

4.2 Ausblick

4.2.1 Optimierung der Laufzeit von graphletAnalyser

4.2.2 Ähnlichkeitssuche

4.2.3 *Graphlets* im Faltungsraum

4.2.4 *Graphlet*-Motive

Kapitel 5

Anhang

5.1 Bildverzeichnis




Abbildung 5.1: Graphlets der Größe 3 (*Shervashidze et al.*)




Abbildung 5.2: Graphlets der Größe 4 (*Shervashidze et al.*)

5.2 Tabellenverzeichnis




Abbildung 5.3: Graphlets der Größe 5 (*Shervashidze et al.*)

PDB-ID	1vib	1qpu	1qq3	2xl6	2yll	1rxq	2qe9	2rd9	1m4r	1hgu	1pv6	lawr	1d9c	1ngl	1n7v	7tim	1ney	1v3z	1al7	1ar0	2v5l
2utg	X	8.626	8.150	9.759	13.62	6.408	8.128	7.384	5.158	4.944	3.570	11.67	4.392	7.387	13.02	9.171	8.737	8.025	2.490	9.329	6.253
1vib	X	8.915	15.89	16.89	21.08	15.22	16.80	16.23	13.39	13.26	17.13	12.32	12.55	11.80	17.87	17.44	17.07	13.78	7.943	16.33	14.27
1qpu	X	8.626	15.54	3.655	5.632	6.272	8.187	7.539	5.410	7.849	7.087	11.01	7.053	9.864	12.54	8.261	8.829	8.822	9.192	9.692	6.462
1qq3	X	8.150	15.89	3.614	5.651	6.064	7.554	7.252	5.087	7.413	6.776	11.02	6.721	9.918	12.56	7.787	8.354	8.892	9.531	9.216	6.019
2xl6	X	9.759	16.89	3.655	4.518	5.106	5.523	5.482	5.514	8.147	8.655	8.374	6.685	8.091	9.919	5.950	6.459	6.255	10.30	7.054	4.716
2yll	X	13.62	21.08	5.632	X	7.737	7.197	7.589	8.855	11.36	11.82	11.53	10.34	12.29	12.94	8.343	8.923	10.59	14.75	10.14	8.137
1rxq	X	6.408	15.22	6.064	7.737	X	2.271	1.563	1.846	4.457	4.428	8.105	2.685	6.737	10.11	4.059	4.769	5.299	8.066	5.910	3.043
2qe9	X	8.128	16.80	7.554	7.197	2.271	X	2.024	4.006	6.167	5.959	8.708	4.649	8.068	10.83	4.470	5.180	6.065	6.728	4.542	
2rd9	X	7.384	16.23	7.539	7.252	1.563	2.024	X	3.205	5.325	5.829	7.137	3.853	6.677	9.126	3.049	3.785	4.747	9.046	5.086	3.123
1m4r	X	5.158	13.39	5.087	5.514	1.846	4.006	3.205	X	3.657	3.784	8.468	1.837	6.243	10.41	5.063	5.650	5.068	6.336	5.972	2.922
1hgu	X	4.944	13.26	7.849	8.147	4.457	6.167	5.325	3.657	X	4.692	9.337	3.187	5.776	10.59	6.059	5.603	6.003	7.045	6.636	3.742
1pv6	X	3.570	11.67	8.655	11.82	4.428	5.959	5.829	3.784	4.692	X	12.09	4.568	8.081	13.67	7.678	8.304	8.510	4.926	9.202	5.753
lawr	X	11.67	17.13	8.374	11.53	8.105	8.708	7.137	8.468	9.337	12.09	X	7.762	7.577	2.196	4.751	4.070	3.972	11.87	3.395	6.506
1d9c	X	4.392	12.55	7.053	10.34	2.685	4.649	3.853	1.837	3.187	4.568	7.702	X	6.366	9.743	5.605	5.246	4.468	5.626	6.116	3.637
1ngl	X	7.387	11.80	9.864	8.091	6.737	8.068	6.677	6.243	5.776	8.081	7.577	6.366	X	8.064	6.805	6.711	4.658	8.473	5.325	4.582
1n7v	X	13.02	12.54	12.56	12.94	10.11	10.83	9.126	10.41	10.59	13.67	2.196	9.743	8.064	X	6.405	5.675	5.484	13.53	4.509	7.987
7tim	X	9.171	17.44	7.787	8.343	4.059	4.470	3.049	5.063	6.059	7.678	4.751	5.605	6.805	6.405	X	0.919	3.869	11.02	2.858	3.619
1ney	X	8.737	17.07	8.829	8.923	4.769	5.180	3.785	5.650	5.603	8.304	4.070	5.246	6.711	5.675	0.919	X	3.500	10.59	2.683	3.646
1v3z	X	8.025	13.78	8.892	6.255	5.299	6.065	4.747	5.068	6.003	8.510	3.972	4.468	4.658	5.484	3.869	3.500	X	8.286	2.693	3.435
1al7	X	2.490	7.943	9.192	10.30	8.066	9.575	9.046	6.336	7.045	4.926	11.87	5.626	8.473	13.53	11.02	10.59	8.286	X	10.56	7.612
1ar0	X	9.329	16.33	9.692	10.14	5.910	6.728	5.086	5.972	6.636	9.202	3.395	6.116	5.325	4.509	2.858	2.683	2.693	10.56	X	3.679
2v5l	X	6.253	14.27	6.462	8.137	3.043	4.542	3.123	2.922	3.742	5.753	6.506	3.637	4.582	7.987	3.619	3.646	3.435	7.612	3.679	X

PDB-ID	1qpu	1qq3	1cgn	1he9	3gf9	1exs	1ngl	1qqs	3slo	1wjx	5chy	2id9	3i42	1d4o	2w0i
1qpu	X	1.139	1.296	6.159	5.656	10.52	11.00	12.35	12.45	11.66	7.517	6.128	6.625	7.326	8.572
1qq3	1.139	X	1.310	5.980	5.645	9.964	10.38	11.61	11.84	11.10	6.967	5.776	6.039	7.491	8.059
1cgn	1.296	1.310	X	6.093	5.737	9.987	10.44	11.55	11.81	11.16	6.801	5.663	5.929	7.091	7.918
1he9	6.159	5.980	6.093	X	2.289	8.032	6.813	11.03	10.87	8.405	3.974	2.445	3.452	10.93	4.807
3gf9	5.656	5.645	5.737	2.289	X	9.544	8.479	12.36	12.19	10.03	5.135	3.370	4.359	12.08	6.018
1exs	10.52	9.964	9.987	8.032	9.544	X	4.463	4.041	3.138	2.802	4.773	7.086	5.541	7.374	4.530
1ngl	11.00	10.38	10.44	6.813	8.479	4.463	X	7.716	6.865	3.764	4.718	6.054	5.065	9.755	4.031
1qqs	12.35	11.61	11.55	11.03	12.36	4.041	7.716	X	1.674	5.340	8.148	10.20	8.612	7.226	7.404
3slo	12.45	11.84	11.81	10.87	12.19	3.138	6.865	1.674	X	4.750	7.488	9.994	8.600	7.680	6.997
1wjx	11.66	11.10	11.16	8.405	10.03	2.802	3.764	5.340	4.750	X	5.264	7.522	5.699	8.450	4.384
5chy	7.517	6.967	6.801	3.974	5.135	4.773	4.718	8.148	7.488	5.264	X	2.600	2.817	8.667	1.497
2id9	6.128	5.776	5.663	2.445	3.370	7.086	6.054	10.20	9.994	7.522	2.600	X	2.447	10.24	3.657
3i42	6.625	6.039	5.929	3.452	4.359	5.541	5.065	8.612	8.600	5.699	2.817	2.447	X	9.544	2.817
1d4o	7.326	7.491	7.091	10.93	12.08	7.374	9.755	7.226	7.680	8.450	8.667	10.24	9.544	X	8.970
2w0i	8.572	8.059	7.918	4.807	6.018	4.530	4.031	7.404	6.997	4.384	1.497	3.657	2.817	8.970	X

Tabelle 5.1: Distanzen der Aminosäuregraphen, gemessen mit RGF. In den Zellen der Tabelle stehen die RGF-Distanzen für die entsprechenden PDB-Dateien. Für jede Zeile (jedes Protein) sind die 4 niedrigsten Distanzen grün unterlegt. Je dunkler das grün ist, desto kürzer ist die Distanz

PDB-ID	1qpu	1qq3	1cgn	1he9	3gf9	1exs	1ngl	1qqs	3slo	1wjx	5chy	2id9	3i42	1d4o	2w0i
1qpu	X	0.806	0.606	0.697	3.131	1.159	2.195	2.197	1.226	1.049	1.014	0.811	1.098	0.628	0.972
1qq3	0.806	X	0.405	1.504	1.567	1.703	0.883	0.883	1.396	1.270	0.869	0.405	0.693	0.988	1.779
1cgn	0.606	0.405	X	0.810	1.432	1.633	1.193	1.193	1.513	1.339	1.060	0.811	1.098	1.011	1.516
1he9	0.697	1.504	0.810	X	4.492	3.253	1.386	1.386	4.357	1.291	1.135	1.099	1.386	3.599	2.506
3gf9	3.131	1.567	1.432	4.492	X	2.523	2.815	2.817	1.596	2.056	1.816	1.917	2.034	3.122	4.130
1exs	1.159	1.703	1.633	3.253	2.523	X	1.324	1.324	2.968	0.696	0.885	1.492	1.610	3.102	3.820
1ngl	2.195	0.883	1.193	1.386	2.815	1.324	X	0.002	0.787	2.629	2.279	0.788	0.286	0.980	2.722
1qqs	2.197	0.883	1.193	1.386	2.817	1.324	0.002	X	0.787	2.631	2.281	0.788	0.285	0.980	2.722
3slo	1.226	1.396	1.513	4.357	1.596	2.968	0.787	0.787	X	0.257	0.705	1.024	1.073	3.137	6.154
1wjx	1.049	1.270	1.339	1.291	2.056	0.696	2.629	2.631	0.257	X	1.043	0.933	0.914	0.644	2.093
5chy	1.014	0.869	1.060	1.135	1.816	0.885	2.279	2.281	0.705	1.043	X	0.607	0.800	0.275	2.282
2id9	0.811	0.405	0.811	1.099	1.917	1.492	0.788	0.788	1.024	0.933	0.607	X	0.692	0.783	2.890
3i42	1.098	0.693	1.098	1.386	2.034	1.610	0.286	0.285	1.073	0.914	0.800	0.692	X	1.076	3.008
1d4o	0.628	0.988	1.011	3.599	3.122	3.102	0.980	0.980	3.137	0.644	0.275	0.783	1.076	X	4.406
2w0i	0.972	1.779	1.516	2.506	4.130	3.820	2.722	2.722	6.154	2.093	2.282	2.890	3.008	4.406	X

Tabelle 5.2: Distanzen der Proteingraphen, gemessen mit RGF. In den Zellen der Tabelle stehen die RGF-Distanzen für die entsprechenden PDB-Dateien. Für jede Zeile (jedes Protein) sind die 4 niedrigsten Distanzen grün unterlegt. Je dunkler das grün ist, desto kürzer ist die Distanz

PDB-ID	1qpu	1qq3	1cgn	1he9	3gf9	1exs	1ngl	1qqs	3slo	1wjx	5chy	2id9	3i42	1d4o	2w0i
1qpu	X	4.405	5.056	2.271	10.75	3.567	2.309	13.66	14.10	2.128	1.933	2.165	1.877	8.791	4.422
1qq3	4.405	X	1.906	1.714	10.03	3.860	3.457	6.851	12.70	2.587	2.431	2.557	2.269	7.907	3.002
1cgn	5.056	1.906	X	0.985	9.469	1.712	1.979	7.333	12.20	1.954	1.120	0.249	0.037	6.501	0.980
1he9	2.271	1.714	0.985	X	5.881	3.456	1.386	4.069	5.432	1.466	1.291	1.099	1.386	9.950	2.506
3gf9	10.75	10.03	9.469	5.881	X	5.473	4.230	14.86	15.99	2.516	1.971	2.575	2.693	8.811	11.61
1exs	3.567	3.860	1.712	3.456	5.473	X	1.290	3.217	4.391	0.611	0.662	1.459	1.576	9.191	4.226
1ngl	2.309	3.457	1.979	1.386	4.230	1.290	X	3.637	2.620	2.697	2.644	0.788	0.286	4.373	2.722
1qqs	13.66	6.851	7.333	4.069	14.86	3.217	3.637	X	12.90	5.645	4.202	3.394	3.512	16.22	4.907
3slo	14.10	12.70	12.20	5.432	15.99	4.391	2.620	12.90	X	4.974	3.863	2.351	2.412	14.09	7.116
1wjx	2.128	2.587	1.954	1.466	2.516	0.611	2.697	5.645	4.974	X	0.360	0.961	0.965	2.225	2.042
5chy	1.933	2.431	1.120	1.291	1.971	0.662	2.644	4.202	3.863	0.360	X	0.797	0.914	1.728	2.093
2id9	2.165	2.557	0.249	1.099	2.575	1.459	0.788	3.394	2.351	0.961	0.797	X	0.692	1.921	2.890
3i42	1.877	2.269	0.037	1.386	2.693	1.576	0.286	3.512	2.412	0.965	0.914	0.692	X	2.039	3.008
1d4o	8.791	7.907	6.501	9.950	8.811	9.191	4.373	16.22	14.09	2.225	1.728	1.921	2.039	X	10.76
2w0i	4.422	3.002	0.980	2.506	11.61	4.226	2.722	4.907	7.116	2.042	2.093	2.890	3.008	10.76	X

Tabelle 5.3: Distanzen der Komplexgraphen, gemessen mit RGF. In den Zellen der Tabelle stehen die RGF-Distanzen für die entsprechenden PDB-Dateien. Für jede Zeile (jedes Protein) sind die 4 niedrigsten Distanzen grün unterlegt. Je dunkler das grün ist, desto kürzer ist die Distanz

PDB-ID	1qpu	1qq3	1cgn	1he9	3gf9	1exs	1ngl	1qqs	3slo	1wjx	5chy	2id9	3i42	1d4o	2w0i
1qpu	X	1.0	1.0	0.621	0.666	0.276	0.25	0.25	0.224	0.25	0.538	0.714	0.5	0.363	0.333
1qq3	1.0	X	1.0	0.621	0.621	0.304	0.276	0.304	0.224	0.25	0.578	0.666	0.666	0.428	0.463
1cgn	1.0	1.0	X	0.621	0.714	0.333	0.224	0.224	0.224	0.276	0.5	0.666	0.578	0.333	0.428
1he9	0.621	0.621	0.621	X	0.935	0.463	0.428	0.176	0.276	0.304	0.621	0.875	0.764	0.333	0.463
3gf9	0.666	0.621	0.714	0.935	X	0.276	0.333	0.2	0.2	0.224	0.621	0.764	0.621	0.25	0.463
1exs	0.276	0.304	0.333	0.463	0.276	X	0.621	0.621	0.764	0.875	0.666	0.5	0.578	0.463	0.818
1ngl	0.25	0.276	0.224	0.428	0.333	0.621	X	0.276	0.428	0.666	0.621	0.538	0.578	0.463	0.666
1qqs	0.25	0.304	0.224	0.176	0.2	0.621	0.276	X	1.0	0.621	0.5	0.276	0.395	0.463	0.463
3slo	0.224	0.224	0.224	0.276	0.2	0.764	0.428	1.0	X	0.538	0.463	0.333	0.395	0.463	0.5
1wjx	0.25	0.25	0.276	0.304	0.224	0.875	0.666	0.621	0.538	X	0.538	0.363	0.5	0.395	0.621
5chy	0.538	0.578	0.5	0.621	0.621	0.666	0.621	0.5	0.463	0.538	X	0.818	0.764	0.428	1.0
2id9	0.714	0.666	0.666	0.875	0.764	0.5	0.538	0.276	0.333	0.363	0.818	X	0.818	0.304	0.621
3i42	0.5	0.666	0.578	0.764	0.621	0.578	0.578	0.395	0.395	0.5	0.764	0.818	X	0.333	0.714
1d4o	0.363	0.428	0.333	0.333	0.25	0.463	0.463	0.463	0.463	0.395	0.428	0.304	0.333	X	0.333
2w0i	0.333	0.463	0.428	0.463	0.463	0.818	0.666	0.463	0.5	0.621	1.0	0.621	0.714	0.333	X

Tabelle 5.4: Jaccard-Indizes der Aminosäuregraphen. In den Zellen der Tabelle stehen die Jaccard-Indizes für die entsprechenden PDB-Dateien. Für jede Zeile (jedes Protein) sind die 4 größten Indizes grün unterlegt. Je dunkler das grün ist, desto größer der Index

PDB-ID	1qpu	1qq3	1cgn	1he9	3gf9	1exs	1ngl	1qqs	3slo	1wjx	5chy	2id9	3i42	1d4o	2w0i
1qpu	X	0.764	0.764	0.578	0.463	0.463	0.621	0.621	0.428	0.578	0.666	0.666	0.666	0.538	0.395
1qq3	0.764	X	0.935	0.764	0.463	0.621	0.714	0.714	0.538	0.714	0.764	0.875	0.818	0.666	0.5
1cgn	0.764	0.935	X	0.764	0.428	0.578	0.714	0.714	0.538	0.666	0.714	0.875	0.818	0.621	0.463
1he9	0.578	0.764	0.764	X	0.463	0.578	0.621	0.621	0.578	0.538	0.621	0.714	0.714	0.666	0.538
3gf9	0.463	0.463	0.428	0.463	X	0.428	0.463	0.463	0.463	0.463	0.538	0.428	0.463	0.5	0.333
1exs	0.463	0.621	0.578	0.578	0.428	X	0.5	0.5	0.714	0.5	0.578	0.666	0.578	0.714	0.621
1ngl	0.621	0.714	0.714	0.621	0.463	0.5	X	1.0	0.538	0.818	0.818	0.818	0.875	0.578	0.395
1qqs	0.621	0.714	0.714	0.621	0.463	0.5	1.0	X	0.538	0.818	0.818	0.818	0.875	0.578	0.395
3slo	0.428	0.538	0.538	0.578	0.463	0.714	0.538	0.538	X	0.538	0.5	0.578	0.621	0.578	0.463
1wjx	0.578	0.714	0.666	0.538	0.463	0.5	0.818	0.818	0.538	X	0.764	0.714	0.818	0.538	0.395
5chy	0.666	0.764	0.714	0.621	0.538	0.578	0.818	0.818	0.5	0.764	X	0.875	0.818	0.621	0.395
2id9	0.666	0.875	0.875	0.714	0.428	0.666	0.818	0.818	0.578	0.714	0.875	X	0.935	0.714	0.463
3i42	0.666	0.818	0.818	0.714	0.463	0.578	0.875	0.875	0.621	0.818	0.818	0.935	X	0.666	0.463
1d4o	0.538	0.666	0.621	0.666	0.5	0.714	0.578	0.578	0.578	0.538	0.621	0.714	0.666	X	0.5
2w0i	0.395	0.5	0.463	0.538	0.333	0.621	0.395	0.395	0.463	0.395	0.395	0.463	0.463	0.5	X

Tabelle 5.5: Jaccard-Indizes der Proteingraphen. In den Zellen der Tabelle stehen die Jaccard-Indizes für die entsprechenden PDB-Dateien. Für jede Zeile (jedes Protein) sind die 4 größten Indizes grün unterlegt. Je dunkler das grün ist, desto größer der Index

PDB-ID	1qpu	1qq3	1cgn	1he9	3gf9	1exs	1ngl	1qqs	3slo	1wjx	5chy	2id9	3i42	1d4o	2w0i
1qpu	X	0.428	0.395	0.428	0.153	0.304	0.395	0.132	0.111	0.363	0.395	0.428	0.428	0.276	0.276
1qq3	0.428	X	0.666	0.621	0.2	0.395	0.5	0.2	0.090	0.5	0.5	0.538	0.538	0.333	0.428
1cgn	0.395	0.666	X	0.621	0.224	0.428	0.5	0.224	0.111	0.463	0.5	0.538	0.538	0.363	0.363
1he9	0.428	0.621	0.621	X	0.25	0.578	0.621	0.153	0.090	0.538	0.621	0.714	0.714	0.428	0.538
3gf9	0.153	0.2	0.224	0.25	X	0.276	0.224	0.153	0.153	0.276	0.304	0.25	0.224	0.276	0.224
1exs	0.304	0.395	0.428	0.578	0.276	X	0.5	0.2	0.153	0.578	0.578	0.666	0.578	0.5	0.621
1ngl	0.395	0.5	0.5	0.621	0.224	0.5	X	0.132	0.132	0.818	0.818	0.818	0.875	0.428	0.395
1qqs	0.132	0.2	0.224	0.153	0.153	0.2	0.132	X	0.224	0.132	0.132	0.132	0.132	0.132	0.2
3slo	0.111	0.090	0.111	0.090	0.153	0.153	0.132	0.224	X	0.111	0.090	0.090	0.111	0.111	0.153
1wjx	0.363	0.5	0.463	0.538	0.276	0.578	0.818	0.132	0.111	X	0.935	0.714	0.818	0.5	0.395
5chy	0.395	0.5	0.5	0.621	0.304	0.578	0.818	0.132	0.090	0.935	X	0.875	0.818	0.5	0.395
2id9	0.428	0.538	0.538	0.714	0.25	0.666	0.818	0.132	0.090	0.714	0.875	X	0.935	0.5	0.463
3i42	0.428	0.538	0.538	0.714	0.224	0.578	0.875	0.132	0.111	0.818	0.818	0.935	X	0.428	0.463
1d4o	0.276	0.333	0.363	0.428	0.276	0.5	0.428	0.132	0.111	0.5	0.5	0.5	0.428	X	0.333
2w0i	0.276	0.428	0.363	0.538	0.224	0.621	0.395	0.2	0.153	0.395	0.395	0.463	0.463	0.333	X

Tabelle 5.6: Jaccard-Indizes der Komplexgraphen. In den Zellen der Tabelle stehen die Jaccard-Indizes für die entsprechenden PDB-Dateien. Für jede Zeile (jedes Protein) sind die 4 größten Indizes grün unterlegt. Je dunkler das grün ist, desto größer der Index

Datensatz	AAG	PG	CG
AAG	1	0.6911	0.7656
PG	0.6911	1	0.6939
CG	0.6939	0.6939	1

Tabelle 5.7: Korrelationen der Ähnlichkeitsbewertungen der verschiedenen Graphformate

Literaturverzeichnis

- [1] Hasegawa et al. Advances and pitfalls of protein structural alignment. *Current Opinion in Structural Biology*, 2009.
- [2] May et al. Ptgl: a database for secondary structure-based protein topologies. *Nucleic Acids Research*, 2010.
- [3] Przölj et al. Modelling interactome: scale-free or geometric. *Bioinformatics*, 2004.
- [4] Chris Sander Liisa Holm. Dali: a network tool for protein structure comparison. *Trends in Biomedical Sciences*, 1995.
- [5] Tim Schäfer, Patrick May, and Ina Koch. Computation and Visualization of Protein Topology Graphs Including Ligand Information. In Sebastian Böcker, Franziska Hufsky, Kerstin Scheubert, Jana Schleicher, and Stefan Schuster, editors, *German Conference on Bioinformatics 2012*, volume 26 of *OpenAccess Series in Informatics (OASIs)*, pages 108–118, Dagstuhl, Germany, 2012. Schloss Dagstuhl–Leibniz-Zentrum fuer Informatik.
- [6] Adam Godzik Yuzhen Ye. Flexible structure alignment by chaining aligned fragment pairs allowing twists. *Bioinformatics*, 2003.